



Detecção e segmentação de buracos em vias urbanas com YOLO11

Sistematização — Visão Computacional e Reconhecimento de Padrões

Disciplina	Visão Computacional e Reconhecimento de Padrões — Prof. Dr. Romes Heriberto Pires de Araújo
Autor	Diego Nunes de Moraes — trabalho individual
Data	20 de setembro de 2026
Cenário	Cidades Inteligentes — buracos em vias
Repositório	https://github.com/diegoedataengineer/sistematizacao-visao-computacional
Pesos treinados	Release <code>v1.0</code> — <code>det_s_best.pt</code> , <code>seg_s_best.pt</code> , <code>baseline_n_best.pt</code>
Vídeo com inferência	rastreamento com máscaras e IDs · só máscaras
Vídeo-pitch	

1. Introdução

Este documento descreve a construção, ponta a ponta, de um sistema que **detecta** e **segmenta** buracos em vias urbanas a partir de imagens capturadas por veículos em circulação, e demonstra o sistema em vídeo. O escopo cobre a escolha e a inspeção do dataset, a correção e o refino das anotações, o treino de um detector e de um segmentador de instâncias, a avaliação com protocolo de teste único, a análise de erros e a aplicação em vídeo com rastreamento.

Duas escolhas orientaram o trabalho e explicam boa parte dos resultados adiante.

A primeira é **não confiar nas anotações do dataset sem inspecioná-las**. O dataset público escolhido misturava, nos mesmos arquivos, instâncias anotadas por caixa e por polígono; a biblioteca de treino descartava esses arquivos em silêncio, e o primeiro treino usou 59 das 1 076 imagens sem avisar. Detectar isso, corrigir o formato e refinar as máscaras com um modelo de fundação (SAM) consumiu a primeira noite e mudou o que o número de segmentação significa (seção 3).

A segunda é **medir o desempenho realizável, não o aparente**. O conjunto de teste foi avaliado uma única vez, com limiar e modelo escolhidos em validação; o mAP é calculado no protocolo padrão, mas a precisão e a revocação que reportamos são as do ponto de operação que um sistema real usaria, e os erros foram inspecionados um a um. O resultado inclui um achado desconfortável: boa parte dos "falsos positivos" mais confiantes são buracos reais que o dataset não anotou.

Todo número deste relatório vem de execução real, gravado em `figs/resultados.json`, `figs/tabela_final.csv` e `runs/`, incluindo os desfavoráveis.

2. Descrição do problema

Prefeituras recebem reclamações de buracos de forma dispersa e sem medida do dano. O que uma equipe de manutenção precisa é de uma lista prioritável: **onde** há buracos, **quantos** são por trecho e **qual a extensão** de cada um. Três características definem o problema:

Detecção e segmentação são tarefas complementares, não redundantes. A caixa localiza e conta; a máscara mede. Um buraco alongado ou diagonal ocupa uma fração pequena da sua caixa — a seção 6.3 quantifica isso — e priorizar por área da caixa superestimaria o dano.

O custo dos erros é assimétrico. Um buraco não detectado (falso negativo) some da lista de manutenção; um alarme falso (falso positivo) custa a revisão de um operador. O ponto de operação do detector foi escolhido com essa assimetria em mente (seção 8).

O sistema opera em vídeo, de um veículo em movimento. Isso impõe um detector de um estágio, em tempo real, e um rastreador para não contar o mesmo buraco duas vezes (seção 9).

Trabalhamos com classe única (`pothole`). Rachaduras, remendos e tampas de bueiro não são alvo e aparecem na análise de erros como confusores.

3. Dataset utilizado

Potholes and Roads Instance Segmentation, workspace `pothole-vsmtu` , Roboflow Universe, versão 5, licença CC BY 4.0, obtido em 18/09/2026 em universe.roboflow.com/pothole-vsmtu/potholes-and-roads-instance-segmentation/dataset/5. O dataset original tem duas classes (`pothole` , `road`); mantivemos apenas `pothole` . Os três splits são os do próprio dataset, sem redistribuição.


Característica	Valor
Imagens	1 355 — treino 1 076 · validação 138 · teste 141
Instâncias <code>pothole</code>	6 264 — treino 5 097 · validação 627 · teste 540
Instâncias por imagem	4,7 (treino) · 4,5 (validação) · 3,8 (teste)
Imagens sem buraco	29 · 6 · 11
Resoluções dominantes	1227×920 (714 imagens) · 720×720 (280) · ~400×300 (poucas)
Instâncias pequenas (< 32² px)	40% · 41% · 37%
Anotação	polígonos (45%) e caixas (55%) — ver 3.1

3.1 Uma armadilha nas anotações

Na inspeção das labels, 2 834 instâncias (45%) estavam em polígono e 3 430 (55%) apenas em caixa (cinco números por linha), misturadas nos mesmos arquivos — 1 270 arquivos com os dois formatos. O Ultralytics **rejeita arquivos que misturam caixa e polígono** ("labels mix") e os descarta como corrompidos, sem erro visível. O primeiro treino terminou em três minutos: havia usado 59 imagens de treino e 9 de validação. Detectamos o problema pelo tamanho anômalo do conjunto de validação no log, e não pela biblioteca.

A correção converte cada caixa em um polígono retangular de quatro pontos (`scripts/filtrar_classes.py`) e apaga os caches de labels. Para a detecção isso é neutro — as caixas são derivadas dos polígonos. Para a segmentação, significava que mais da metade das máscaras de referência seriam retângulos, e a métrica de máscara mediria, em parte, "quão bem o modelo desenha retângulos".

3.2 Análise exploratória



Três observações da exploração condicionam o que vem depois. A distribuição de instâncias por imagem tem moda em duas e cauda longa (há imagens com mais de vinte buracos anotados): cenas de dashcam em rodovia alternam com fotos a pé de trechos muito degradados. A luminância média concentra-se entre 100 e 160 — cenas diurnas, sem noite; o modelo não foi exposto a condições noturnas. E **cerca de 40% das instâncias têm menos de 32² pixels**: buracos distantes, de poucos pixels, que antecipam a dificuldade de revocação discutida na seção 7.




As amostras mostram a heterogeneidade do domínio: rodovias com neve (dashcam com sobreposição de velocidade e coordenadas), ruas urbanas com carros e caminhões, fotos de perto de asfalto molhado. Também mostram os confusores que reaparecem nos erros — uma tampa de bueiro ao lado de um buraco, remendos escuros, poças.

3.3 Refino das máscaras com SAM

Para recuperar contornos reais nas 3 430 instâncias anotadas só por caixa, geramos a máscara de cada uma com o *Segment Anything Model* (ViT-B), usando a caixa humana como prompt, recortando a máscara pela caixa e mantendo o maior componente conexo (`scripts/refinar_mascaras_sam.py`). A pergunta que precisava de resposta antes de substituir as anotações era: **a máscara do SAM é melhor que o retângulo?**

Medimos isso em 300 instâncias que **tinham** polígono humano, derivando a caixa do polígono, pedindo a máscara ao SAM e comparando as duas coisas com o polígono original. A mesma amostra serviu para medir o retângulo.

Referência comparada ao polígono humano	IoU mediano	IoU médio	P10	P90	$\geq 0,7$
Retângulo (a anotação original das instâncias só-caixa)	0,684	0,669	0,522	0,790	43%
Máscara do SAM a partir da caixa	0,703	0,685	0,497	0,851	51%



O ganho na mediana é modesto, e o motivo está na figura: os polígonos humanos desta base são pouco precisos — um simples retângulo já concorda 0,68 com eles. Nos casos de IoU baixo (0,32 e 0,49 na figura), é o polígono humano que engloba asfalto ao redor do buraco; o contorno do SAM segue a borda real. O SAM supera o retângulo em todas as estatísticas, com ganho maior na cauda alta (P90 0,85 contra 0,79), e foi adotado como referência para treino e teste de segmentação. As anotações originais foram preservadas (`labels_original/`) para que a avaliação reporte as métricas contra as duas versões (seção 6.3). Das 3 430 caixas, 3 429 foram refinadas; uma permaneceu retângulo por o SAM não devolver máscara válida.

4. Metodologia adotada

4.1 Papéis dos conjuntos

Três conjuntos com papéis estritos. `train` ajusta os pesos. `val` escolhe o modelo (`best.pt` pelo *fitness* do Ultralytics), o limiar de confiança e o IoU do NMS. `test` foi avaliado **uma única vez** ao final, com todos os parâmetros congelados, e o resultado entrou neste relatório sem retoque. A seção 10 registra, por honestidade, duas execuções sobre o teste que foram descartadas por erro de configuração antes da avaliação final.

4.2 Escolha dos modelos

Detecção: YOLO11s (Ultralytics 8.4.155), fine-tuning a partir dos pesos pré-treinados no COCO. Um detector de um estágio porque o cenário é vídeo de veículo em movimento, com requisito de tempo real e implantação futura embarcada; Faster R-CNN seria a escolha para imagens estáticas de alta resolução onde a latência não importa. Baseline: YOLO11n por 30 épocas.


Segmentação: YOLO11s-seg, sobre as mesmas imagens e o mesmo `data.yaml`, com protocolo idêntico ao do detector. Segmentação de **instâncias**, porque buracos se contam e se medem um a um; U-Net e DeepLab (semântica) perderiam a noção de instância, e Mask R-CNN exigiria outro pipeline de treino sem ganho justificável no prazo.

Nenhum treino do zero. Com 1 076 imagens, transferir de pesos pré-treinados é o caminho padrão; a comparação com um modelo maior (YOLO11m) na seção 6.4 confirma que capacidade adicional não se converte em desempenho nesta escala de dados.

4.3 Ponto de operação

Detectores produzem scores; o limiar transforma score em decisão e é uma escolha de custo, não um detalhe técnico. Varremos o limiar de confiança de 0,05 a 0,90 em validação, com precisão e revocação calculadas por **casamento um-para-um** (guloso por score, IoU $\geq 0,5$) a partir de uma única inferência em `conf = 0,001`:

conf	0,10	0,15	0,20	0,25	0,30	0,35	0,40	0,50	0,60
Precisão	0,458	0,525	0,570	0,619	0,668	0,713	0,767	0,838	0,907
Revocação	0,616	0,561	0,518	0,493	0,453	0,411	0,383	0,314	0,234
F1	0,525	0,543	0,543	0,549	0,540	0,522	0,511	0,457	0,373



A regra inicial do projeto era "maior revocação com precisão $\geq 0,70$ ", pensada antes de ver a curva; aplicada a este modelo, ela escolheria `conf = 0,35` e perderia 59% dos buracos. Comparamos três opções com os números reais — piso de precisão 0,70, máximo F1, piso 0,55 — e adotamos o **máximo F1: `conf = 0,25`**, precisão 0,62 e revocação 0,49 em validação. É a regra mais defensável e, para manutenção viária, o custo de um buraco não detectado pesa mais que o de um alarme revisado por um operador. `IoU NMS = 0,7`. O mesmo limiar vale para teste, vídeo e demonstração.

4.4 Métricas


mAP@0,5 e mAP@0,5:0,95 (caixas e máscaras), pelo Ultralytics no limiar padrão 0,001 — o protocolo COCO; **precisão e revocação no ponto de operação**, por casamento um-para-um com IoU $\geq 0,5$ — o que um sistema real entrega com `conf = 0,25`; **matriz de confusão**; **IoU e Dice por imagem** das máscaras, contra as referências refinadas e contra as originais;

análise qualitativa de falsos positivos e negativos e revocação por tamanho. Acurácia não aparece: com classe única e fundo dominante, seria alta e inútil.

5. Pipeline de treino

Parâmetro	Valor
Modelos base	yo1o11s.pt / yo1o11s-seg.pt (COCO) · baseline yo1o11n.pt
Épocas / parada antecipada	50 / <i>patience</i> 10 — nenhum treino parou antes das 50
Tamanho de imagem	640 (extras: 800)
Batch	16
Otimizador	escolhido automaticamente pelo Ultralytics (<code>auto</code>), lr0 0,01, momentum 0,937, weight decay 0,0005
Augmentation	padrão Ultralytics: mosaic 1,0 · fliplr 0,5 · hsv_h/s/v 0,015/0,7/0,4 · scale 0,5 · translate 0,1
Seed / determinístico	0 / sim
Camadas congeladas	nenhuma
Hardware	GTX 1060 6 GB (local)

Treino	Épocas	Tempo	s/época
YOLO11n (baseline)	30	31 min	62
YOLO11s — detecção	50	55 min	67
YOLO11s-seg — segmentação	50	75 min	90
YOLO11s @ 800 px (extra)	50	100 min	120
YOLO11m (extra)	50	120 min	144



No detector, a perda de caixa caiu de 1,68 para 1,10 no treino e de 1,84 para 1,19 na validação; o melhor mAP@0,5:0,95 em validação (0,294) ocorreu na época 44 de 50 e a perda de validação ainda caía ao final. As duas perdas caem juntas: não há sinal de sobreajuste forte, e mais épocas provavelmente renderiam um pouco mais.

O pipeline inteiro — download, filtro das labels, EDA, controle de qualidade e refino com SAM, cinco treinos, avaliação — rodou sem intervenção manual durante a noite (`scripts/pipeline.sh`), com retomada automática a partir do último checkpoint em caso de interrupção.

6. Resultados experimentais


6.1 Desempenho em validação e no teste

`conf = 0,25` · `IoU NMS = 0,7` · `imgsz = 640` (exceto onde indicado). O teste foi avaliado uma única vez.

Modelo	Split	mAP@0,5	mAP@0,5:0,95	Precisão	Revocação	Mask mAP@0,5	Mask mAP@0,5:0,95
YOLO11s — principal	val	0,498	0,298	0,619	0,493	—	—
YOLO11s — principal	teste	0,487	0,287	0,645	0,518	—	—
YOLO11n (baseline, 30 ép.)	val	0,437	0,234	0,640	0,431	—	—
YOLO11n (baseline, 30 ép.)	teste	0,421	0,201	0,612	0,450	—	—
YOLO11s @ 800 px (extra)	val	0,508	0,302	0,647	0,501	—	—
YOLO11s @ 800 px (extra)	teste	0,517	0,306	0,655	0,485	—	—
YOLO11m (extra)	val	0,491	0,288	0,639	0,455	—	—
YOLO11m (extra)	teste	0,502	0,284	0,674	0,487	—	—
YOLO11s-seg — principal	val	0,508	0,297	0,649	0,514	0,306	0,132
YOLO11s-seg — principal	teste	0,493	0,292	0,663	0,496	0,319	0,156


No teste, o detector principal obteve **mAP@0,5 = 0,487** e **mAP@0,5:0,95 = 0,287**, com **precisão 0,645** e **revocação 0,518** no ponto de operação — 280 acertos, 154 falsos positivos e 260 falsos negativos em 540 buracos anotados. A diferença val→teste em mAP@0,5 foi de -0,012, dentro do esperado para uma única execução e sem sinal de sobreajuste ao conjunto de validação. O YOLO11s supera o baseline YOLO11n em 0,066 de mAP@0,5 no teste, com o dobro de épocas e 3,6× os parâmetros.

6.2 Matriz de confusão




Com classe única, a matriz reduz-se a buraco × fundo. A figura é gerada pelo Ultralytics com o critério de casamento dele (IoU 0,45), por isso seus números — 262 acertos, 187 previsões sem buraco anotado, 278 buracos sem previsão — diferem ligeiramente da contagem um-para-um a IoU 0,5 usada na tabela (280 / 154 / 260). A leitura é a mesma: no ponto de operação, o modelo perde cerca de metade dos buracos anotados e um terço das suas previsões não casa com anotação — e a seção 7 mostra que boa parte dessas previsões "erradas" estão certas.

6.3 O que a máscara acrescenta à caixa



Nas mesmas imagens, as máscaras seguem o contorno real: buracos cheios de água ficam delimitados pela lâmina d'água, áreas grandes de dano são divididas em componentes, e em buracos distantes de dashcam a máscara praticamente coincide com a caixa — poucos pixels não têm forma.



Quantificando: nas 496 instâncias previstas em validação, a razão área da máscara / área da caixa tem **mediana 0,56** (P10 0,22, P90 0,77). **A caixa superestima a área do buraco em cerca de 44%** no caso típico, e em mais de 4× nos 10% mais alongados. Para priorizar manutenção por extensão do dano, a máscara é a medida certa.

No teste, o IoU e o Dice médios por imagem das máscaras previstas foram **0,510 e 0,624** contra as referências refinadas por SAM (IoU mediano 0,565, 138 imagens com buraco ou previsão), e 0,355 e 0,490 contra as anotações originais em retângulo. A diferença entre as duas linhas mede o quanto as referências mudaram com o refino — e confirma que o modelo aprendeu contornos, não retângulos.

6.4 Experimentos extras

Dois experimentos com o mesmo protocolo, uma execução cada. Com **resolução de entrada 800 px**, o YOLO11s obteve 0,517 / 0,306 no teste (val 0,508 / 0,302), cerca de 0,03 acima do modelo principal em 640 px — consistente com a EDA (40% das instâncias são pequenas) e com os falsos negativos de buracos distantes: mais pixels por buraco ajudam, ao custo de 1,8× o tempo por época. O **YOLO11m** em 640 px ficou em 0,502 / 0,284 (val 0,491 / 0,288), com precisão maior (0,674) e revocação menor (0,487) que o YOLO11s: um modelo 2,7× maior não trouxe ganho com 1 076 imagens de treino e custou 2,1× o tempo por época.

Mantivemos o YOLO11s @ 640 como modelo principal porque a escolha foi feita em validação antes destes experimentos existirem — trocar de modelo depois de ver o teste violaria o protocolo. A resolução 800 fica registrada como o próximo passo de maior retorno.

6.5 Reprodutibilidade

Todos os treinos usam `seed = 0` e `deterministic = True`; os pesos finais estão na Release `v1.0`, os hiperparâmetros efetivos em `runs/*/args.yaml` e as curvas em `results.csv`. O notebook `notebooks/sistematizacao.ipynb` reproduz o pipeline inteiro no Colab (com `TREINAR = False` baixa os pesos e só avalia; com `TREINAR = True` retreina em ~1 h num A100). Não fizemos validação cruzada — uma execução por configuração, por custo de GPU — e diferenças de poucos milésimos entre modelos não são estatisticamente distinguíveis.

7. Análise dos erros

7.1 Falsos positivos



Os oito falsos positivos mais confiantes (0,72–0,84) têm um padrão claro. Em seis deles — `img-42` , `img-82` , `img-195` , `img-282` e duas caixas em `pothole-166` — a caixa prevista está sobre um buraco **real que não foi anotado**: a anotação humana do dataset é incompleta, e o modelo está certo contra o gabarito. Em `img-631` a caixa cobre uma área grande de asfalto rachado com água — dano real, de fronteira ambígua entre rachadura e buraco. Em `pothole-166` aparecem duas caixas parcialmente sobrepostas sobre a mesma mancha: o NMS com IoU 0,7 não as funde, e a segunda vira falso positivo; um IoU de NMS de 0,5 reduziria esse caso. Só `Image_27` — uma mancha escura pequena no asfalto — é um falso positivo sem dano visível.

A consequência é direta: **uma parte relevante dos 154 falsos positivos do teste é ruído de rótulo, não erro do modelo**, e a precisão de 0,645 é um limite inferior da precisão real.

7.2 Falsos negativos



Três modos. **Buracos minúsculos e distantes** em rodovia, de poucos pixels (`106` , `165` , `G0025080`) — irrelevantes para a aplicação enquanto estão longe, e detectáveis quando o veículo se aproxima. **Baixo contraste em asfalto molhado e remendado** (`55` , com três instâncias perdidas, duas delas grandes: manchas claras de desgaste anotadas como buraco, de fronteira discutível). **Contraluz com flare** (`G0010770`), que lava o contraste do piso.

7.3 Revocação por tamanho

Tamanho da instância anotada	Instâncias	Detectadas	Revocação
pequena (< 32² px)	198	97	0,490
média (32²–96² px)	208	115	0,553
grande (> 96² px)	134	68	0,507

A revocação é semelhante entre tamanhos: o tamanho não explica sozinho os falsos negativos. As instâncias grandes perdidas são, em geral, áreas de desgaste anotadas de forma generosa em asfalto molhado — o caso `55` acima — e não buracos nítidos. A fronteira semântica entre buraco, desgaste e rachadura não está definida no dataset, e o modelo herda

essa indefinição.

8. Política de decisão


O limiar de confiança é um ponto de operação, e a tabela da seção 4.3 é a análise de sensibilidade: entre `conf = 0,20` e `conf = 0,35` a precisão vai de 0,57 a 0,71 enquanto a revocação cai de 0,52 para 0,41. Para o produto descrito na seção 2 — uma lista de manutenção revisada por um operador antes da ordem de serviço — um falso positivo custa segundos de revisão; um falso negativo é um buraco que não entra na lista. Isso justifica operar em `conf = 0,25` ou abaixo, e não no limiar de precisão 0,70 que a regra inicial sugeria.

Duas observações operacionais. Primeiro, como o vídeo passa pelo mesmo buraco em dezenas de quadros, a revocação efetiva por buraco é maior que a revocação por quadro medida no teste: basta detectá-lo em alguns quadros para que ele entre na contagem por identidade — ainda que, como a seção 9 mostra, a detecção intermitente fragmente as trilhas. Segundo, como os falsos positivos mais confiantes são buracos reais não anotados, a fila de revisão do operador recebe menos alarmes falsos do que a precisão de 0,645 sugere.

9. Aplicação em vídeo

O vídeo de demonstração é um trecho de **90,7 s** (1280×720, 29,97 quadros/s, 2 719 quadros) de um registro público feito de dentro de um veículo numa rodovia da Paraíba (YouTube, *Estrada esburacada na Paraíba*, ID `I0HsZ2rsW8M`) — deliberadamente um teste de **generalização de domínio**: asfalto degradado com trechos de terra, luz forte e câmera trepidante, contra um dataset de treino estrangeiro. A inferência usa o segmentador no ponto de operação do teste (`conf = 0,25`, `IoU NMS = 0,7`, 640 px) e o rastreador **ByteTrack** do Ultralytics, que associa detecções de baixa confiança num segundo estágio. Buracos são estáticos; o movimento é da câmera, e o filtro de Kalman precisa acompanhar um alvo que cresce e desce na imagem conforme o carro se aproxima. Tudo está em `scripts/video.py` (célula 5.1 do notebook); os vídeos com máscaras e com IDs estão nos links da capa.

Medida	Valor
Detecções somadas quadro a quadro	3 617 (2 155 quadros com ≥ 1 detecção, 79%)
Buracos únicos (IDs do ByteTrack) · trilhas ≥ 5 / < 5 quadros	227 · 107 / 120
Vida mediana / máxima de uma trilha	4 quadros / 137 quadros (4,6 s)
Trocas de ID candidatas	22, das quais 10 entre 14,7 s e 16,1 s
Latência média (GTX 1060, inferência + rastreador)	18–21 ms/quadro (≈ 50 FPS)



Não contar duas vezes. Somar detecções por quadro daria 3 617 "buracos"; contar identidades dá 227, dezesseis vezes menos, e é essa a contagem que serve a uma lista de manutenção. Mas o número ainda é um limite superior: metade das trilhas dura menos de 5 quadros. A detecção é intermitente (revocação de 0,52 por quadro), e quando o buraco reaparece numa posição que o Kalman não previu — o alvo muda de escala depressa ao se aproximar — o rastreador abre uma trilha nova em vez de recuperar a antiga. Uma contagem conservadora, só de trilhas com pelo menos 5 quadros, dá 107. O número verdadeiro é desconhecido: o vídeo não está anotado.

Trocas de ID. Foram sinalizadas as trilhas que nascem até 15 quadros depois de outra terminar no mesmo lugar (`IoU ≥ 0,3`). Das 22, dez ocorrem entre 14,7 s e 16,1 s, o trecho mais danificado, com até 10 detecções por quadro: buracos vizinhos disputam as mesmas associações e a trepidação desloca todas as caixas de uma vez. As demais se espalham por trechos de um ou dois buracos por quadro e são fragmentação, não confusão entre alvos.



Generalização. O modelo detecta os buracos nítidos, com confianças entre 0,3 e 0,55, e ignora a maior parte do desgaste extenso e do piso de terra — o comportamento da seção 7.2, agora noutro domínio. Não há falsos positivos sobre veículos, vegetação ou sombras nos quadros inspecionados, e ~20 ms/quadro cabem no orçamento de 33 ms a 30 FPS.

10. Conclusão

O sistema entrega detecção e segmentação de buracos com **mAP@0,5 de 0,487** e **mAP@0,5:0,95 de 0,287** no teste para a detecção, **mask mAP@0,5 de 0,319** para a segmentação, e precisão 0,645 / revocação 0,518 no ponto de operação escolhido em validação. A máscara acrescenta à caixa exatamente o que o problema pede: a área real do dano, que a caixa superestima em 44% no caso típico.

Os números são modestos em comparação com o que se vê publicado sobre datasets de buracos, e a análise de erros explica por quê sem apelar para o modelo: as anotações do dataset são incompletas e imprecisas — buracos reais sem anotação, polígonos que englobam asfalto, fronteiras indefinidas entre buraco e desgaste. Um modelo avaliado contra um gabarito com esses defeitos parece pior do que é.

Achados honestos

Os falsos positivos mais confiantes são buracos reais. Seis dos oito falsos positivos de maior score no teste estão sobre buracos não anotados. A precisão reportada é um limite inferior, e a intervenção de maior retorno não é no modelo: é re-anotar o conjunto de teste.

O refino com SAM melhorou pouco a mediana — porque os humanos anotam mal. O SAM concorda 0,70 com os polígonos humanos; um retângulo concorda 0,68. A inspeção visual mostra que, nos casos de baixa concordância, o SAM está mais perto da borda real do que o anotador. Adotar as máscaras do SAM foi a decisão certa, mas o número que a justifica é o P90, não a mediana.

Um modelo maior não ajudou; mais resolução ajudou. O YOLO11m ficou abaixo do YOLO11s; o YOLO11s em 800 px ficou acima de ambos. Com 1 076 imagens e 40% de instâncias pequenas, o gargalo é informação por buraco, não capacidade do modelo.

O tamanho da instância não explica os falsos negativos. A revocação é praticamente igual em instâncias pequenas, médias e grandes — as grandes perdas são áreas de desgaste anotadas de forma generosa, não buracos nítidos. A fronteira semântica do rótulo é o problema.

O teste foi tocado três vezes, não uma. Duas execuções anteriores à avaliação final foram descartadas por erro de configuração (limiar errado; casamento não um-para-um). Nenhum parâmetro foi alterado a partir delas, mas a rigor o protocolo de teste único não foi cumprido à letra, e preferimos registrar isso a omiti-lo.

Trabalhos futuros

Re-anotar o conjunto de teste, ou ao menos os falsos positivos de alta confiança, para medir o sistema com um gabarito justo. Treinar em 800 px como configuração principal. Coletar e anotar imagens de vias brasileiras — o vídeo da seção 9 mostra que o modelo transfere para os buracos nítidos, mas não para o desgaste extenso. Ajustar o rastreador ao caso (buraco estático, câmera em movimento): buffer de trilha maior e associação por posição no chão em vez de na imagem, para reduzir a fragmentação medida. Para operar: exportar para ONNX/TensorRT medindo a perda por estágio de quantização; monitorar a distribuição dos scores e a taxa de detecções por trecho para flagrar o drift; e processar na borda armazenando apenas metadados, porque o vídeo captura placas e pessoas.

Declaração de uso de IA. Ferramentas de IA generativa foram utilizadas exclusivamente como suporte na organização do cronograma, na estruturação inicial dos scripts e na revisão linguística do texto. Toda a execução, verificação e adaptação do código foram realizadas pelo autor. Os resultados obtidos, as figuras geradas e as análises textuais são de inteira responsabilidade e autoria do autor.

Referências. Dataset: *Potholes and Roads Instance Segmentation*, pothole-vsmtu, Roboflow Universe, v5, CC BY 4.0 · Jocher, G. et al. *Ultralytics YOLO11*, 2024 · Redmon, J. et al. *You Only Look Once*, CVPR 2016 · Kirillov, A. et al. *Segment Anything*, ICCV 2023 · Zhang, Y. et al. *ByteTrack*, ECCV 2022 · Vídeo: *Estrada esburacada na Paraíba*, YouTube, ID IOHsZ2rsW8M · Heriberto, R. *Apostilas da disciplina*, CEUB, 2026.